GRAPHRAG

Demo: CineGraph - AI-powered movie query application

Nguyen Tri Cao

cao.nguyen@sotatek.com

Ngày 4 tháng 2 năm 2026

Abstract

Mục lục

Page

1 Introduction **3**

1.1 Bối cảnh & Vấn đề: Điểm hạn chế của RAG truyền thống với câu hỏi toàn cục (Global Sensemaking) 3

2 Background **4**

2.1 About RAG Baseline: Vector Search + Chunking 4

2.2 About GraphRAG 4

3 POC **13**

3.1 Thiết lập Môi trường & Dữ liệu 13

3.2 End-to-End 13

3.3 Evaluation 13

4 Result & Analysis **14**

5 Recommendations and Conclusion **15**

References **15**

1 Introduction

1.1 Bối cảnh & Vấn đề: Điểm hạn chế của RAG truyền thống với câu hỏi toàn cục (Global Sensemaking)

1.1.1 Bối cảnh:

Nhắc lại một chút về RAG - một kỹ thuật để cải thiện đầu ra của các mô hình ngôn ngữ lớn (LLM) bằng cách sử dụng thông tin từ tài liệu cụ thể để nó có thể trả lời tốt trong phạm vi cụ thể đó. Kỹ thuật này là một phần quan trọng của hầu hết các công cụ dựa trên LLM và phần lớn các phương pháp RAG sử dụng similarity vector làm kỹ thuật tìm kiếm (search engine), hướng tiếp cận này được gọi là Baseline RAG.

1.1.2 Vấn đề

Các kỹ thuật RAG đã cho thấy triển vọng trong việc giúp các LLM lý luận về các tập dữ liệu riêng tư - dữ liệu mà LLM không được đào tạo và chưa bao giờ thấy trước đó, chẳng hạn như nghiên cứu độc quyền, tài liệu kinh doanh hoặc giao tiếp của một doanh nghiệp. Baseline RAG được tạo ra để giúp giải quyết vấn đề này, nhưng khi triển khai sẽ có những tình huống mà Baseline RAG hoạt động rất kém:

- Baseline RAG gặp khó khăn khi nối kết các điểm thông tin. Điều này xảy ra khi trả lời một câu hỏi đòi hỏi phải đi qua các mảnh thông tin khác nhau, đôi khi thông tin sẽ khá rắc rối, sau đó được tổng hợp lại. Và đôi khi do sự phức tạp hoặc dư thừa từ dữ liệu đưa vào mà LLM trả lời sai.
- Baseline RAG hoạt động rất kém (chứ không muốn nói là fail) khi được yêu cầu hiểu một cách toàn diện một thông tin nào đó trên các bộ sưu tập dữ liệu lớn hoặc thậm chí trên các tài liệu lớn. Ví dụ đưa cho nó một tập lớn các điều lệ công ty và bảo nó tóm tắt tất cả điều lệ công ty, thì baseline RAG xịt keo ngay.

Để giải quyết vấn đề này, GraphRAG ra đời - 1 phương pháp mới của Microsoft Research. GraphRAG, sử dụng các LLM để tạo ra một đồ thị tri thức dựa trên một tập hợp đầu vào. Hiểu đơn giản thì thay vì lưu trữ các chunk text và embedding nó để search, thì GraphRAG biểu diễn và lưu trữ dưới dạng đồ thị, cùng các kỹ thuật nâng cao về gom nhóm, tìm kiếm để đưa ra câu trả lời tối ưu nhất, khắc phục được 2 nhược điểm bên trên. GraphRAG cho thấy sự cải thiện đáng kể, vượt trội hơn so với các phương pháp khác đã được áp dụng trước đó đối với các tập dữ liệu riêng tư.

2 Background

2.1 About RAG Baseline: Vector Search + Chunking

RAG (Retrieval-Augmented Generation), thường được gọi là Vector RAG hoặc Naive RAG, là nền tảng phổ biến nhất hiện nay. Nó hoạt động dựa trên một quy trình tuần tự đơn giản: chia nhỏ văn bản, biểu diễn thành vector, tìm kiếm theo ngữ nghĩa và tổng hợp câu trả lời. Luồng xử lý được mô tả ở hình 2.1 .

2.1.1 Chunking

Mục đích các tài liệu dài thành các đoạn văn bản nhỏ (chunks) có kích thước phù hợp để nhúng (embed) và nạp vào context window của LLM.
Phương pháp phổ biến:

- Chunk theo kích thước cố định: 512 hoặc 1024 tokens, có thể có phần chồng lấn (overlap) giữa các chunk để tránh mất ngữ cảnh.
- Chunk theo ngữ nghĩa: Dựa trên cấu trúc văn bản (đoạn văn, tiêu đề).

Hạn chế: Việc chia cắt có thể làm đứt gãy mạch ngữ nghĩa tự nhiên và các mối quan hệ logic vốn trải dài qua nhiều đoạn văn.

2.1.2 Vector Search

- **Embedding Model:** Mô hình (như text-embedding-3-small) chuyển đổi mỗi chunk văn bản thành một vector số học đa chiều, mã hóa ý nghĩa ngữ nghĩa của nó.
- **Vector Database:** Cơ sở dữ liệu chuyên dụng (như LanceDB, Pinecone, Weaviate) lưu trữ các vector này cùng với siêu dữ liệu (metadata) tham chiếu về chunk gốc. Nó hỗ trợ tìm kiếm nhanh chóng các vector "gần nhau"nhất trong không gian đa chiều.

2.2 About GraphRAG

2.2.1 Index

Quá trình Index của GraphRAG với mục tiêu lưu chung là lưu trữ thông tin để phục vụ Query, và việc lưu trữ này dưới dạng đồ thị. Trong đồ thị thì có 2 thành phần không thể thiếu, đó là Node và Edge.

1)TextUnit

TextUnit là một mảnh (chunk) văn bản được tạo ra từ Document để làm “đơn vị phân tích” cho toàn bộ pipeline. Kích thước chunk (tính theo token), overlap, và cách bám theo ranh giới dữ liệu (document boundary / group-by) đều cấu hình được. TextUnits đóng vai trò rất quan trọng cho truy vết nguồn (breadcrumbs/provenance): các tri thức trích xuất (entity/relationship/claim) có thể “tham chiếu ngược” về TextUnits để biết nó đến từ đoạn nào.

2)Extract entities, Relationships, Claims

Đây là bước LLM "đọc hiểu"và trừu tượng hóa thông tin từ TextUnits thành cấu trúc tri thức.

- **Entities:** Có title, type, description. Các đối tượng có tên và ý nghĩa (Người, Tổ chức, Địa điểm, Khái niệm...). Ví dụ: "Công ty SotaTek", "Ronaldo".
- **Relationships:** Có source, target, description. Mối liên kết có ý nghĩa giữa hai thực thể. Ví dụ: "Quantum Systems sở hữu NeoChip".
- **Claims (Optional):** là workflow độc lập để trích xuất claims từ TextUnits. Claims là các phát biểu thực tế (positive factual statements) có trạng thái đánh giá và ràng buộc thời gian. Docs mô tả claims được lưu dưới dạng covariates và thường cần prompt tuning để phù hợp ngữ cảnh dữ liệu. Các phát biểu sự thật hoặc sự kiện cụ thể liên quan đến thực thể. Ví dụ: "Cổ phiếu của NeoChip tăng mạnh trong tuần đầu giao dịch."

Merge + Summarize: Các subgraph theo TextUnit sẽ được gộp (entity trùng title-type được merge; relationship trùng source-target được merge), rồi dùng LLM để tóm tắt danh sách mô tả thành một mô tả gọn cho mỗi node/edge trong graph.

3)Community detection (hierarchical clustering/Leiden)

Sau khi có graph Entities–Relationships, GraphRAG chạy Hierarchical Leiden community detection để tạo cấu trúc phân cụm phân cấp (hierarchy) và tìm các cụm node liên quan chặt chẽ .

Mục đích: Từ đồ thị thực thể-quan hệ (các node và edge), tìm ra các cụm (community) gồm những thực thể có kết nối chặt chẽ với nhau hơn là với phần còn lại của đồ thị. Thuật toán Leiden: Được GraphRAG sử dụng vì nó tạo ra các community liên thông tốt và có thể chạy đệ quy để phát hiện các community con bên trong một community lớn.

- Cấp 0 (Root/Gốc): 1 community lớn chứa toàn bộ đồ thị.
- Cấp 1: 5 community chính (ví dụ: "Chủ đề Công nghệ", "Chủ đề Chính sách").
- Cấp 2: 15 community con (ví dụ: "AI Ethics"bên trong "Chủ đề Công nghệ").

4)Generate Community Summaries

Đây là bước tổng hợp tri thức quan trọng nhất, tạo ra "chỉ mục thông minh"cho GraphRAG. Khi đã có hierarchy communities, GraphRAG tạo Community Reports bằng LLM để cung cấp hiểu biết tổng quan ở nhiều mức:

- Community top-level → report mang tính “toàn cục” của cả graph
- Community level thấp → report mang tính “cục bộ” của một cụm nhỏ

Generate Community Reports: LLM tạo report cho từng community để nêu thông tin “distinct” của community, và report sẽ tham chiếu các key entities, relationships, và claims trong cấu trúc community đó. Summarize Community Reports: Sau đó mỗi report lại được tóm tắt thành bản ngắn (summary) để dùng nhanh khi truy vấn. Đồ thị cùng các communities có thể xem hình 2.2 minh họa dưới đây:

2.2.2 Query

1)Global Search

Kỹ thuật này phù hợp với các câu hỏi mang tính toàn diện, tổng quan về dữ liệu, truy vấn toàn cục để "Thấy Rừng", những câu hỏi mang tính khái quát chung mà RAG truyền thống có khả năng fail cao. Nhờ vào việc gom nhóm các entities và relationships vào các community, thì lúc này ta sẽ dựa vào mô tả của các communities đó. Được xử lý theo cơ chế Map-Reduce

- **Map:**
  - Các community summaries được shuffle và chia thành các chunks với fix token size
  - Dùng LLM sinh ra mỗi câu trả lời cho 1 chunk cùng với score (0-100) (tùy bài toán)
- **Reduce:**
  - Sort các câu trả lời theo score
  - Đưa vào LLM các câu trả lời này cho tới khi limi token để sinh ra global answer (target)

Câu hỏi phù hợp: Câu hỏi cần hiểu biết tổng thể, phân tích xu hướng, tóm tắt chủ đề trên toàn bộ dữ liệu.

Ví dụ: "Các chủ đề công nghệ nổi bật nhất trong năm là gì?", "Đâu là những rủi ro chính được đề cập xuyên suốt các báo cáo dự án?"

2)Local Search

Kỹ thuật này phù hợp với các câu hỏi sâu về một chủ đề nào đó, phù hợp để suy luận sâu hơn về các thực thể và các mối quan hệ láng giềng, truy vấn cục bộ để "Xem Cây"

- **Xác định thực thể liên quan:** Local Search xác định một tập hợp các thực thể từ knowledge graph có liên quan về mặt ngữ nghĩa với query của người dùng. Các thực thể này đóng vai trò là endpoint vào knowledge graph, cho phép trích xuất thêm các chi tiết liên quan như các entities được kết nối/liên quan, relationships, biến cố của thực thể và summary reports.
- **Trích xuất thông tin:** Ngoài ra, Local Search cũng trích xuất các đoạn văn bản có liên quan từ các tài liệu đầu vào thô được liên kết với các entities đã xác định.
- **Ưu tiên và lọc:** Các nguồn dữ liệu ứng viên này sau đó được ưu tiên và lọc để phù hợp với một cửa sổ ngữ cảnh đơn lẻ có kích thước được xác định trước, được sử dụng để tạo phản hồi cho truy vấn của người dùng.

Câu hỏi phù hợp: Câu hỏi xoáy sâu vào một đối tượng cụ thể, yêu cầu phân tích chi tiết, mối quan hệ và ngữ cảnh xung quanh.

Ví dụ: "Công ty Alpha đã hợp tác với những ai và trong các dự án nào?", "Nguyên nhân và diễn biến chính của sự cố X là gì?"

3)DRIFT Search

Là một phương pháp lai (hybrid) kết hợp điểm mạnh của cả Local và Global Search. "DRIFT"(tạm hiểu: lan tỏa) mở rộng phạm vi tìm kiếm cục bộ bằng cách đưa thêm ngữ cảnh toàn cục từ các Community Reports có liên quan, truy vấn Kết hợp để "Xem Cả Rừng lẫn Cây"

- Bắt đầu như Local Search: Xác định thực thể/chủ đề trọng tâm và thu thập ngữ cảnh đồ thị cục bộ.
- Mở rộng bằng Global Context: Hệ thống xác định các Community Reports nào có chứa hoặc liên quan đến thực thể/chủ đề đó.
- Kết hợp ngữ cảnh: Ngữ cảnh cục bộ (chi tiết, sâu) được bổ sung bởi các báo cáo cộng đồng liên quan (tổng quan, rộng). Sự kết hợp này cung cấp cả chiều sâu và bề rộng.

- Tạo câu trả lời nâng cao: LLM sử dụng ngữ cảnh kết hợp phong phú này để tạo ra câu trả lời vừa chi tiết, vừa đặt đối tượng vào bức tranh tổng thể lớn hơn.

Câu hỏi phù hợp: Câu hỏi phức tạp, đa lớp, yêu cầu hiểu sâu một đối tượng NHƯNG đồng thời cần đánh giá tác động, vị trí hoặc ý nghĩa của nó trong toàn cục.

Ví dụ: "Vụ bê bối của công ty Beta ảnh hưởng thế nào đến toàn ngành và các chủ đề thảo luận công cộng?", "Phát minh X không chỉ là gì, mà nó còn thúc đẩy những xu hướng nghiên cứu lớn nào khác?"

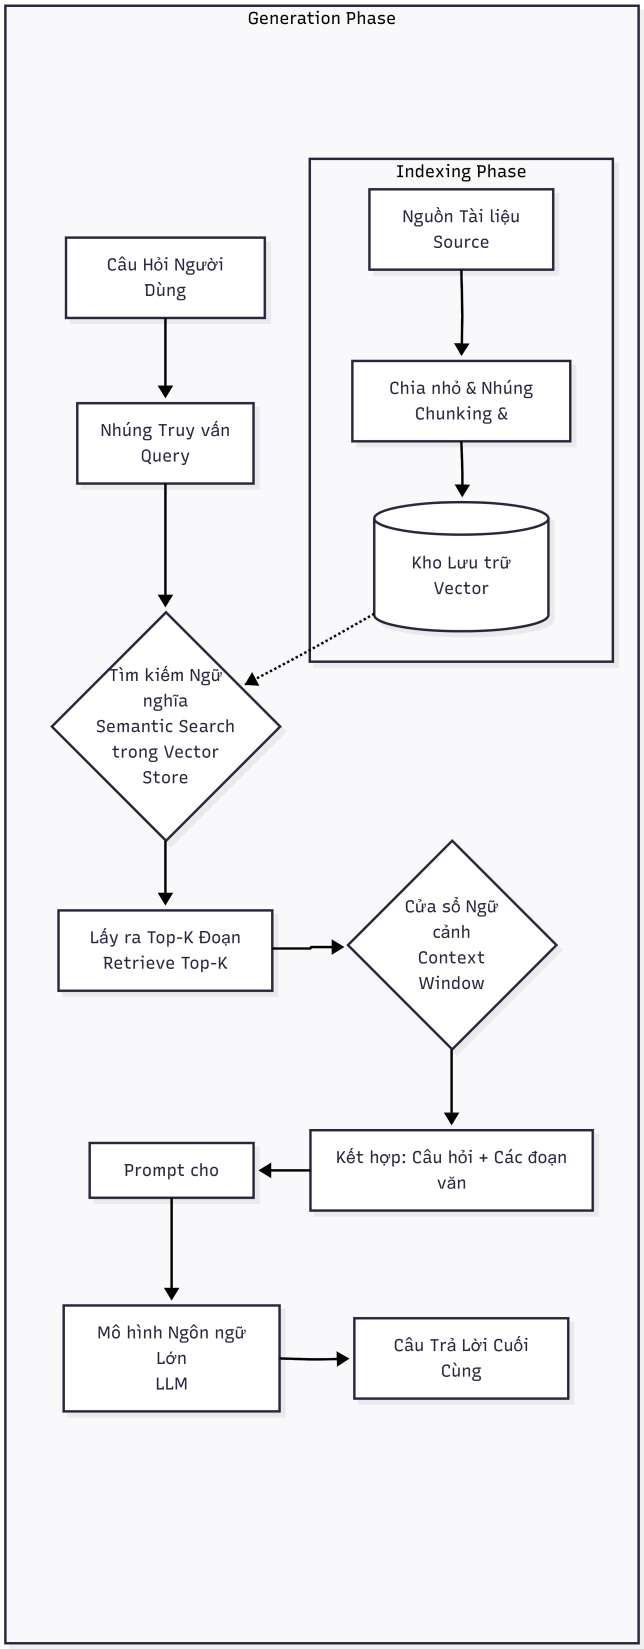

Hình 2.1: RAG Pipeline

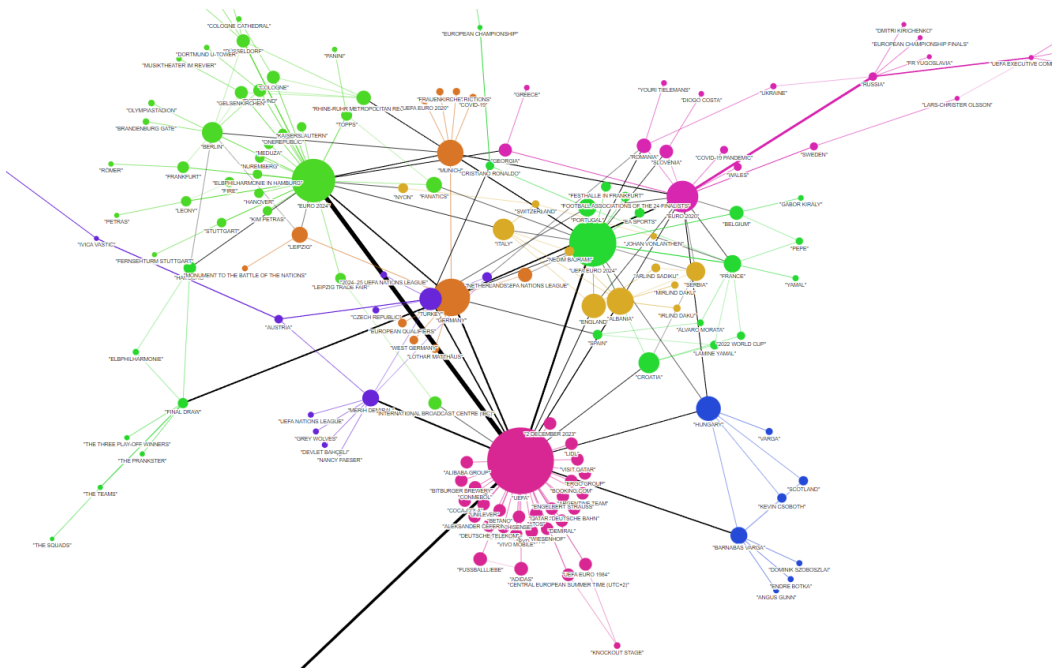

Hình 2.2: Node, Relationship

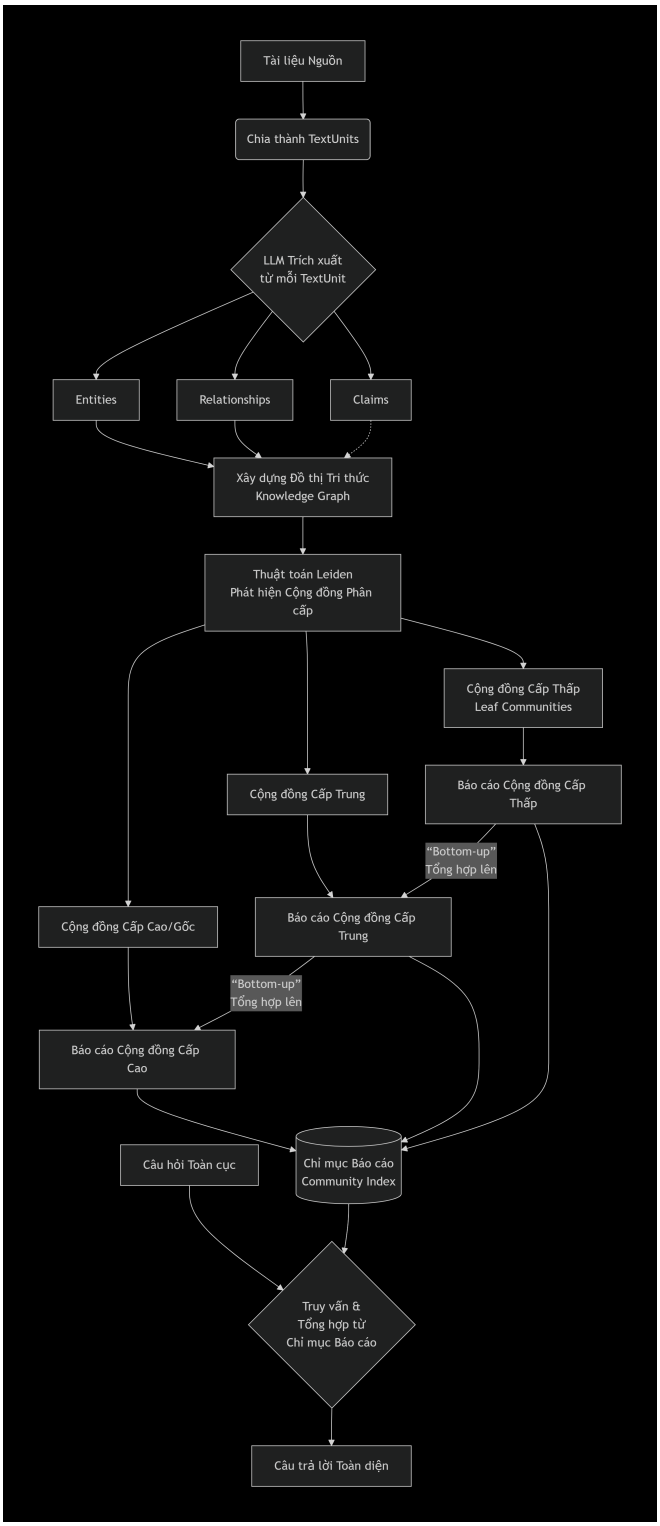

Hình 2.3: Pipeline of GraphRAG

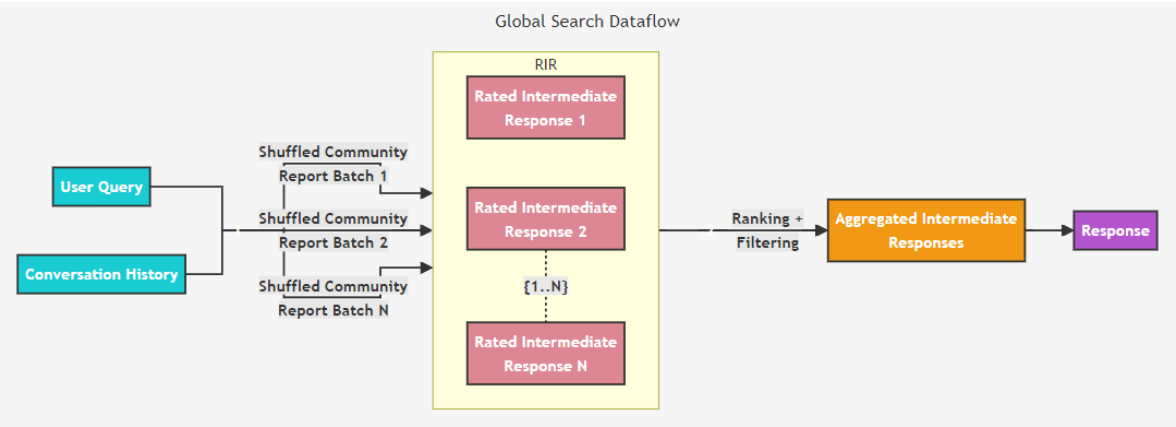

Hình 2.4: Global Search

3 POC

3.1 Thiết lập Môi trường & Dữ liệu

3.1.1 Corpus

3.1.2 GraphRAG

3.2 End-to-End

3.3 Evaluation

4 Result & Analysis

5 Recommendations and Conclusion